

6.5晚实验汇总

核心理论： H_{eff} — 基于噪声信道模型的连续推理深度定义（Week 2 主要进展）

问题起源

原有逻辑约束熵 $H_G = \sum_{i=1}^L \log_2 B_i$ 存在致命盲区：它是一个**一维标量和**，无法区分深窄图和浅宽图。

- **深窄图：** $L = 20$, $B_i \equiv 2$, $H_G = 20$ bit $\rightarrow$ 考验长程一致性与乘性错误坍塌
- **浅宽图：** $L = 2$, $B_1 = 1024$, $H_G \approx 11$ bit $\rightarrow$ 考验局部高维分类

按旧理论它们"一样难"（甚至可以设计成完全相同 H_G ），但物理灾难机制完全不同。 H_G 把深度和宽度这两个正交维度压扁成了一个数字。

理论推导链

第 1 步：推理 = 信号经过串联噪声信道

自回归生成每一步面对 B_i 选 1 的分类问题。正确选项是"信号"， $B_i - 1$ 个错误分支是"噪声"。

核心操作——"抠出 1 比特"：

- 信号功率统一归一化： $S_i = 1$ （任何选择至少需要 1 比特做二元决策）
- 噪声功率： $N_i = \log_2 B_i - 1$ （多出来的不确定性才是纯干扰）

这使得信号和噪声在数学上完全正交：

- 当 $B_i = 2$: $N_i = 0$, $\text{snr}_i \rightarrow \infty$ （理想无噪声信道）
- 当 B_i 很大： $N_i \gg 1$, $\text{snr}_i \rightarrow 0$ （噪声墙）

第 2 步：全局信噪比

$$\text{SNR}_{\text{global}} = \frac{S_{\text{total}}}{N_{\text{total}}} = \frac{L}{\sum_{i=1}^L (\log_2 B_i - 1)}$$

深窄图即使 L 很大，SNR 依然极高；浅宽图即使 L 很小，SNR 骤降。

第 3 步：中断概率分析（深度惩罚的物理来源）

$$P_{\text{success}} = \prod_{i=1}^L (1 - p_i) \leq \exp \left(- \sum_{i=1}^L p_i \right)$$

即使每步错误概率 p_i 极小（如 0.01）， $L = 100$ 时成功率降至 37%。要求准确率 $\geq 1 - \epsilon$ ，必须 $\sum p_i \leq \epsilon$ 。深度本身就成了风险源。

第 4 步：有效逻辑熵 H_{eff}

$$H_{\text{eff}} = \sum_{i=1}^L \log_2 B_i + \beta L$$

- $\sum \log_2 B_i$ ：捕获宽度噪声墙效应
- βL ：捕获深度的乘性错误坍塌效应
- β ：深度惩罚系数，由模型架构决定，需实验标定

第 5 步：与随机熵 H_R 的统一

$$H_R = \sum_{i=1}^L \log_2 V \quad (\text{纯记忆上限})$$

$$\Delta \text{NLL}_{\text{eff}} = H_R - H_{\text{eff}} = \sum_{i=1}^L (\log_2 V - \log_2 B_i) - \beta L$$

物理含义：模型通过逻辑推理**实际能节省**的信息量。单位统一为 bit，可直接做掺杂实验。

第 6 步：不等错误保护（UEP）加权形式

$$H_{\text{SNR-aware}} = \sum_{i=1}^L w_i \log_2 B_i, \quad w_i = e^{\lambda_i} \text{ 或 } w_i = 1 + \gamma(i - 1)$$

刻画"越往后越脆弱"的物理特性——同样的 $\log_2 B_i$ 出现在第 1 步和第 20 步的破坏力不同。

新旧框架对比

维度	原 $H_G = \sum \log_2 B_i$	新 $H_{\text{eff}} = \sum \log_2 B_i + \beta L$
参数化维数	1 维（标量和）	2 维（宽度项 + 深度项）
深窄 vs 浅宽	不可区分	天然解耦
理论基础	纯组合计数	有噪信道编码 + 有限长度界
深度惩罚	无	βL ，有明确物理来源
可证伪性	只能预测"熵越大越难"	可预测准确率崩塌的二维相变边界

与 H_R 衔接	$\Delta\text{NLL} = H_R - H_G$	$\Delta\text{NLL}_{\text{eff}} = H_R - H_{\text{eff}}$ ，完全兼容
------------	--------------------------------	---

理论的已知局限（需诚实对待）

- § 3.3 信道容量推导是推导链中最弱一环：** βL 的最终形式更多来自 § 3.2 中断概率直觉 + 物理合理性论证，而非严格的数学推导。不要宣传成"从 Shannon 定理严格导出"。
- 线性 βL 可能是过度简化：** 深度惩罚可能超线性（ $\beta L^\alpha, \alpha > 1$ ）甚至指数形式（"lost in the middle"、注意力稀释、位置编码退化）。
- 假设步间独立：** 忽略 Transformer 注意力机制的跨步耦合，只抓一阶主效应。
- 未区分"记忆衰减"和"错误传播"：** βL 把两个不同机制装进了一个参数。

已解决的问题

1. H_G 盲区 $\rightarrow H_{\text{eff}}$ 二维解耦

原 H_G 无法区分深窄图和浅宽图。 $H_{\text{eff}} = \sum \log_2 B_i + \beta L$ 将深度和宽度解耦为两个正交维度，一次性解决了这个核心盲区。

2. 逻辑熵训练不收敛

之前尝试用"逻辑熵"作为连续深度度量直接优化，导致 loss 不下降。原因诊断：

- 成功推理的熵不是单调的（低全局均匀性、剧烈信息密度起伏）
- 深度越深，熵可能越发散（IOpenER 现象）
- 熵测量不确定性，不是深度——两者没有单调关系

解决方式： 放弃直接优化熵，转向 Shannon 信息论框架——用 H_{eff} 作为分析工具而非优化目标。

3. 推理深度连续定义的零突破

从零开始，基于通信理论构建了 H_{eff} 定义框架。核心理念：**推理即压缩，深度即噪声**。完成了从问题形式化 $\rightarrow$ 信道建模 $\rightarrow$ 中断概率 $\rightarrow H_{\text{eff}}$ 定义的完整推导链。

4. 与记忆线框架的统一对接

H_{eff} 与 H_R 单位统一 (bit)，掺杂实验设计有明确的物理含义（如"30%随机 + 70%逻辑" $\rightarrow H_{\text{mix}} = 0.3H_R + 0.7H_{\text{eff}}$ ）。

待解决的核心问题

● 问题 1： β 如何测定？

当前方案：

二维网格实验：扫 (L, B) 网格，找准确率崩塌边界，用崩塌边界上的点做线性回归：

$$L \cdot \log_2 B_{\text{crit}} = C_{\text{phys}} - \beta \cdot L$$

斜率取负即为 β 。

但这里存在一个严重的 confounding factor（见问题 2）。

● 问题 2：模型对推理深度的泛化会不会影响 β 的测量？

这是目前最需要认真对待的核心方法论问题。

问题描述

The Depth Ceiling 论文揭示了一个关键现象：

如果在低深度的训练集上训练模型，模型能在 loss 较小的基础上较好地完成 DAG 寻路任务，并且测试发现还有泛化到更深梯度的能力。

然而，如果一上来就给高深度的训练集（随机 + 逻辑序列混合），模型完全不能收敛，最终学不会探路。

这个现象的含义是：模型的推理能力存在一个"训练深度天花板"——不是模型推理能力的绝对上限，而是训练数据深度超过某个阈值后，学习过程本身就会崩溃。

这对 β 测量的影响

在二维网格实验中测 β 时，我们实际测量的是：

$$\beta_{\text{measured}} = \beta_{\text{true}} + \beta_{\text{generalization gap}}$$

其中：

- β_{true} ：模型架构本身的深度惩罚系数（我们想测的物理量）
- $\beta_{\text{generalization gap}}$ ：模型因训练数据深度分布而产生的泛化偏差

场景分析：

场景	训练深度	测试深度	测得的 β	问题
----	------	------	-------------	----

A	低深度 ($L_{\text{train}} \leq 5$)	逐步加深	β 偏小 (模型泛化能力强, 崩塌边界后移)	低估了架构本身的深度惩罚
B	高深度 ($L_{\text{train}} \geq 15$)	逐步加深	模型根本不收敛, 无法测量	实验无法进行
C	中等深度 ($L_{\text{train}} \approx 10$)	逐步加深	β 接近真实但仍有偏	需要校准

核心矛盾:

- 如果训练深度太低 $\rightarrow$ 模型泛化到高深度, 测得的 β 会比真实值**偏小** (因为泛化能力掩盖了部分深度惩罚)
- 如果训练深度太高 $\rightarrow$ 模型根本不收敛, 实验无法进行 (天花板效应)
- 我们永远只能在一个"中间地带"测量, 而这个测量结果本身是训练深度分布的函数

如何排除泛化效应以测得 β_{true} ?

思路 1: 控制训练深度分布, 做消融实验

不是在单一训练深度下测 β , 而是在**多个训练深度**下分别测量:

1. 训练 5 个模型, 训练数据深度上限分别为 $L_{\text{train}}^{\text{max}} = 3, 5, 8, 12, 16$
2. 对每个模型, 在测试时扫 (L, B) 网格测 $\beta_{\text{measured}}(L_{\text{train}}^{\text{max}})$
3. 画 β_{measured} vs $L_{\text{train}}^{\text{max}}$ 曲线
4. 如果曲线趋于平稳 (饱和), 饱和值接近 β_{true}
5. 如果曲线持续下降, 说明 β_{measured} 永远包含泛化效应

关键检验: 如果 β_{measured} 随 $L_{\text{train}}^{\text{max}}$ 增大而增大并收敛到一个上界, 那么这个上界就是 β_{true} 。物理直觉: 当训练深度足够大, 模型已经没有"多余的泛化余量"可以调用, 此时测得的崩塌才是架构本身的限制。

思路 2: 泛化 gap 的显式建模

将崩塌边界条件扩展为：

$$L_{\text{test}} \cdot \log_2 B + \beta_{\text{true}} \cdot L_{\text{test}} + \gamma \cdot (L_{\text{test}} - L_{\text{train}}^{\max})_+ = C_{\text{phys}}$$

其中 γ 是泛化衰减系数， $(x)_+ = \max(0, x)$ 表示只在测试深度超过训练深度时才有额外惩罚。

通过变化 $L_{\text{train}}^{\max}$ 和 L_{test} 两个维度，可以联合拟合 β_{true} 和 γ 。

思路 3：训练深度匹配测试深度（消除泛化 gap）

对每个测试点 (L, B) ，用恰好相同深度的训练数据训练一个模型（或 fine-tune），然后在该点测试。这样 $L_{\text{test}} = L_{\text{train}}^{\max}$ ，泛化 gap 项 $(L_{\text{test}} - L_{\text{train}}^{\max})_+ = 0$ 。

但此方案的问题：

- 计算量极大（每个 (L, B) 组合训一个模型）
- 高深度训练可能不收敛，导致该数据点缺失
- 实践中只能做稀疏采样

思路 4（推荐）：分阶段实验设计

Plain Text

- 1 阶段 A：泛化能力标定（先搞清楚泛化本身）
- 2 - 固定一个简单拓扑（如 $B=2$ ）
- 3 - 变化 $L_{\text{train}} \in \{2, 3, 4, 5, 6, 8, 10, 12\}$
- 4 - 对每个 L_{train} ，测试模型在 $L_{\text{test}} \in \{L_{\text{train}}, L_{\text{train}}+1, \dots, L_{\text{train}}+10\}$ 上的准确率
- 5 - 绘制"泛化衰减曲线"：accuracy vs $(L_{\text{test}} - L_{\text{train}})$
- 6 - 目的：量化"模型从训练深度向外泛化时，每多一步损失多少准确率"
- 7
- 8 阶段 B： β 标定（在控制泛化效应的前提下）
- 9 - 选择 3 个 L_{train} 水平（低/中/高）
- 10 - 对每个 L_{train} ，只在 $L_{\text{test}} \leq L_{\text{train}} + \text{合理泛化范围}$ 内扫 (L, B)
- 11 - 对每个 L_{test} 层，分别回归 β
- 12 - 比较不同 L_{train} 下的 β 是否一致
- 13 - 如果一致 $\rightarrow \beta$ 是稳健物理量，泛化效应已被控制
- 14 - 如果不一致 $\rightarrow \beta$ 本身是 L_{train} 的函数，需要在论文中坦诚并建模
- 15
- 16 阶段 C：泛化天花板验证
- 17 - 验证 The Depth Ceiling 的发现是否在 H_{eff} 框架下成立
- 18 - 检验：当 H_{eff} 超过某临界值时，即使降低训练深度也无法泛化
- 19 - 这直接检验"深度天花板"是否是 H_{eff} 的函数

● 问题 3: βL 的线性假设是否成立?

$H_{\text{eff}} = \sum \log_2 B_i + \beta L$ 中假设深度惩罚是线性的, 但实际可能是:

- **超线性** $\beta L^\alpha (\alpha > 1)$: 错误滚雪球, 越往后越容易错
- **指数** $\beta e^{\lambda L}$: 功亏一篑效应, 后期脆弱性指数爆炸
- **对数** $\beta \ln L$: 注意力机制对长文本的平滑容量, 边际递减

应对策略 (论文叙事三段式):

1. **阶段一 (基准模型)**: 提出线性 H_{eff} 作为一阶近似基准线 (Baseline)
2. **阶段二 (证伪)**: 用实验数据展示反解出的 β 不是常数, 随 L 退化 $\rightarrow$ 证明一阶假设不够
3. **阶段三 (非线性修正)**: 将公式升级为 $H_{\text{eff}} = \sum \log_2 B_i + f(L)$, 暴力试错拟合 $f(L)$ 的最优形式。这是论文的真正 Contribution

● 问题 4: 均匀出度实验是否能泛化到非均匀真实拓扑?

质疑: 现实中图拓扑错综复杂, B_i 忽大忽小, 实验中统一出度的理论有什么泛化价值?

防御策略:

1. **控制变量法话术**: 固定出度 $B_i \equiv B$ 是为了在各向同性 (Isotropic) 的理想拓扑信道中, 实现对深度特征 $f(L)$ 的**纯净测量**。类比物理学中的"无摩擦表面"或"理想气体"——建立普遍定律的必经基准。
2. **几何平均等价映射**:

$$\sum_{i=1}^L \log_2 B_i = L \cdot \log_2 \bar{B}_{\text{geo}}, \quad \bar{B}_{\text{geo}} = (B_1 B_2 \cdots B_L)^{1/L}$$

任何一个出度不均匀的复杂系统, 在信息论尺度上都等价于一个出度恒为 $\bar{B}_{\text{geo}}$ 的均匀系统。

3. **UEP 通用模板**: $H_{\text{eff}} = \sum_{i=1}^L w(i, L) \log_2 B_i$, 每个 B_i 独立, 权重 $w(i, L)$ 从受控实验中拟合得到。

新实验精细规划

总体实验架构: 三阶段递进

Plain Text

- 1 阶段 1: 泛化能力标定 (解决 confounding factor)
- 2 ↓
- 3 阶段 2: β 测定 + 线性假设检验 (二维网格核心实验)

阶段 1：泛化能力标定实验

目的：在测 β 之前，先搞清楚模型对推理深度的泛化规律，为后续 β 测量提供校准基线。

实验 1.1：泛化衰减曲线

逻辑序列构造：

- 固定 $B = 2$ （最简单拓扑，排除宽度干扰，纯粹测量深度效应）
- 训练深度 $L_{\text{train}} \in \{2, 3, 4, 5, 6, 8, 10, 12\}$
- 对每个 L_{train} ，生成训练集：每个深度 5000 个不同 DAG（随机种子变化）
- 测试深度 $L_{\text{test}} \in \{L_{\text{train}}, L_{\text{train}} + 1, \dots, L_{\text{train}} + 10\}$ （上限 25）

关键测量指标：

- 完全匹配准确率（Exact Match）
- 部分匹配率（前 k 步正确的比例， $k = 1, 2, \dots, L_{\text{test}}$ ）
- 首次错误位置分布

预期产出：

- 泛化衰减曲线： $\text{accuracy}(L_{\text{test}} | L_{\text{train}})$
- "泛化余量"：模型能比训练深度多走几步？
- 衰减模式：线性衰减？悬崖式崩塌？

值得探讨的点：

- 泛化能力是否随 L_{train} 增加而递减？（训练越深，泛化余量越小？）
- 是否存在一个"临界训练深度"，超过后泛化能力骤降？（与 The Depth Ceiling 呼应）
- 部分匹配率 vs 完全匹配率：模型是在哪一步开始"迷失"的？是逐步退化还是突然崩溃？

实验 1.2：宽度对泛化的调制效应

逻辑序列构造：

- 固定 $L_{\text{train}} = 5$

- 变化 $B \in \{2, 4, 8, 16\}$
- 测试时变化 L_{test} 和 B_{test} (可以 $B_{\text{test}} \neq B_{\text{train}}$)

目的：验证"在低宽度下训练的模型，泛化到高宽度时是否更困难？"还是"宽度和深度的泛化是独立的？"

值得探讨的点：

- 如果模型在 $B = 2$ 训练但在 $B = 8$ 测试，深度泛化能力是否衰减？
- 这是否意味着宽度和深度共享同一套"泛化预算"？

阶段 2: β 测定核心实验

实验 2.1: 二维网格崩塌边界扫描 (主实验)

逻辑序列构造 (均匀出度):

采用**分层 DAG 生成法** (见 [week2/实验设计.md](#)):

1. 将全图 V 个节点划分到 $L + 1$ 个层 (Layer 0 到 Layer L)
2. Layer 0 仅包含起点 s ; Layer L 仅包含终点 t
3. 对第 i 层每个节点: 随机从第 $i + 1$ 层抽取 1 个节点作为正确后继 (串联成唯一最短路径), 再随机抽取 $B - 1$ 个节点作为干扰后继
4. **好处:** 生成瞬间即知 $H_G = L \cdot \log_2 B$, 无需事后计算

参数网格:

- L (步数): 2, 3, 4, 5, 6, 8, 10, 12, 15, 20
- B (每步分支数): 2, 3, 4, 6, 8, 12, 16, 24, 32, 48, 64, 128, 256, 512, 1024
- 每个 (L, B) 组合: 50 个随机种子 $\rightarrow$ 共 $10 \times 15 \times 50 = 7500$ 个独立 DAG

训练策略 (基于阶段 1 的发现调整):

- 先在多个 L_{train} 下训练 (如 $L_{\text{train}} \in \{3, 5, 8\}$), 得到多个模型
- 对每个模型分别测崩塌边界
- 比较不同 L_{train} 下的 β_{measured}

值得探讨的点:

- 训练集的深度分布应该如何设计? 全部统一深度 vs 混合多种深度?

- 混合深度可能让模型学到更鲁棒的推理策略，但会引入新的 confounding
- 建议：先做统一深度（控制变量），再做混合深度（逼近真实场景）
- 训练时 B 应该如何设置？固定 B 还是混合 B ？
 - 固定 B ：训练集所有 DAG 出度相同 → 纯净测量
 - 混合 B ：训练集中包含不同出度的 DAG → 更接近真实分布，但 β 的含义变模糊
 - 建议：先在固定 B 下测 β 作为 " β 在特定宽度下的条件值"，再测试 β 是否随训练 B 变化

实验 2.2：线性假设检验

崩塌边界回归：

- 对崩塌边界上的点，同时拟合三种形式：
 - $L \cdot \log_2 B = C - \beta L$ （线性）
 - $L \cdot \log_2 B = C - \beta L^\alpha$ （幂律）
 - $L \cdot \log_2 B = C - \beta e^{\lambda L}$ （指数）
- 比较 R^2 、AIC，选最优模型

H_{eff} 等高线验证（最关键的证伪检验）：

- 取崩塌边界上一点 (L_1, B_1) ，计算 $H_{\text{eff}}^{(1)} = L_1 \log_2 B_1 + \beta L_1$
- 构造 (L_2, B_2) 使 $H_{\text{eff}}^{(2)} = H_{\text{eff}}^{(1)}$ （不同 L ，调整 B 使 H_{eff} 相等）
- 预测：如果 $H_{\text{eff}} = \text{const}$ 是真正的等难度线，两组准确率应该相同
- 如果不同 → H_{eff} 作为单标量等难度线的假说被推翻，需要更高维描述

值得探讨的点：

- 如果线性被拒绝， $f(L)$ 的最优形式是否在不同 B 区间一致？还是说小 B 和大 B 下的深度惩罚机制不同？
- $f(L)$ 是否依赖模型尺寸？对 7B/13B 分别测，预期更大模型 $f(L)$ 增长更慢

实验 2.3：非均匀出度验证（泛化性检验）

逻辑序列构造：

- 固定 $L = 8$ ，固定 $\sum \log_2 B_i = 24$ （控制总结构熵不变）

- 变化 B_i 分布：
 - 条件 A (深窄): $B = [2, 2, 2, 2, 2, 2, 2, 2] \rightarrow \sum \log_2 B_i = 8$ (总熵不同, 需调整)
 - 条件 B (均匀中宽): $B = [8, 8, 8, 8, 8, 8, 8, 8] \rightarrow \sum \log_2 B_i \approx 24$
 - 条件 C (单步爆炸前端): $B = [256, 2, 2, 2, 2, 2, 2, 2] \rightarrow \sum \log_2 B_i = 8 + 7 = 15$
 - 条件 D (单步爆炸后端): $B = [2, 2, 2, 2, 2, 2, 2, 256]$
 - 条件 E (递增): $B = [2, 3, 4, 6, 8, 12, 16, 24]$
 - 条件 F (递减): $B = [24, 16, 12, 8, 6, 4, 3, 2]$

目的: 检验 UEP 加权形式是否必要。如果 H_{eff} (常数 β) 能统一描述所有条件, 则加权不必要; 如果条件 C 和 D 的崩塌点不同, 则 UEP 形式被验证。

值得探讨的点:

- "前端爆炸" (第一步噪声极大) vs "后端爆炸" (最后一步噪声极大): 哪个更致命?
 - 前端爆炸 $\rightarrow$ 模型第一步就可能走错, 后续全废
 - 后端爆炸 $\rightarrow$ 功亏一篑效应, 但前期已经建立了正确上下文
 - 如果两者破坏力不同, 说明 w_i 不是均匀的——但 w_i 是递增 (后端更脆弱) 还是递减 (前端更致命)? 这本身就是一个可发表的新发现

阶段 3: 掺杂实验 (记忆-推理统一框架)

实验 3.1: 逻辑-随机连续掺杂

序列构造方法:

- **逻辑部分:** 按上述分层 DAG 生成, 答案序列严格遵循图的最短路径
- **随机部分:** 保持前缀 (问题描述/图结构) 不变, 但将答案序列替换为从词典 V 中**无视连通性、纯随机抽样**的 token 串
 - 此处模型面对的是最大随机搜索熵 $H_R = L \cdot \log_2 V$
- **掺杂控制参数** $\gamma \in [0, 1]$:
 - $\gamma = 0$: 纯逻辑 (H_{eff})
 - $\gamma = 1$: 纯随机 (H_R)

- $\gamma = 0.3$: 30% 的步使用随机 token, 70% 使用逻辑路径

训练集设计要点:

- 同一条序列内部掺杂 vs 不同序列之间的掺杂 (batch 级掺杂)?
 - **推荐序列间掺杂**: batch 中混合纯逻辑样本和纯随机样本, 比例由 γ 控制
 - 序列内掺杂 (同一序列部分步是逻辑、部分步是随机) 会引入诡异的联合分布, 模型可能学到奇怪的 shortcut
- 训练时是否告诉模型当前是逻辑还是随机? (类似 task prefix token)
 - 可以尝试两种设置: 有 task token (告诉模型这是逻辑任务) vs 无 task token (模型自己判断)
 - 有 task token 能帮助收敛但不够"隐式"

值得探讨的点:

- 是否存在一个临界掺杂比例 γ_{crit} , 超过后模型完全放弃推理转而纯记忆?
- γ_{crit} 是否随 L 变化? 深度越大, 模型是否越容易"堕落"到记忆策略?
- 不同 γ 下, 模型的 internal representation 如何变化? (probing 实验)
- 掺杂实验的 loss 曲线是否呈现相变特征?

实验 3.2: $H_{\text{eff}} - H_R$ 连续插值验证

核心预测:

$$\Delta \text{NLL}_{\text{eff}} = H_R - H_{\text{eff}} = \sum (\log_2 V - \log_2 B_i) - \beta L$$

当 H_{eff} 接近模型物理压缩上限 C_{phys} 时, $\Delta \text{NLL}_{\text{eff}} \rightarrow 0$, 模型退化为记忆/瞎猜。

实验设计:

1. 固定 H_R (固定 L 和 V), 逐步降低 H_{eff} (通过降低 B_i 或 L)
2. 测量模型实际 NLL 降低量 $\Delta \text{NLL}_{\text{actual}}$
3. 比较 $\Delta \text{NLL}_{\text{actual}}$ 与 $\Delta \text{NLL}_{\text{eff}}$ 的预测值
4. 检验两者之差是否在 $H_{\text{eff}} \rightarrow C_{\text{phys}}$ 时急剧扩大 $\rightarrow$ 推理-记忆相变

实验设计中需要特别注意的关键点汇总

1. 训练数据的深度分布

- **核心原则：**训练深度分布是一个独立的实验变量，不是 nuisance parameter
- 需要系统地变化 $L_{\text{train}}^{\max}$ ，而不是固定一个"合理"的值
- 如果阶段 1 发现泛化效应显著，则阶段 2 的所有结论都需要标注"在 $L_{\text{train}}^{\max} = X$ 条件下"

2. 随机种子的作用

- 每个 (L, B) 条件需要多个种子 (≥ 50) 以得到稳定的准确率估计
- DAG 的随机生成（哪条是正确路径、干扰边如何连接）会显著影响单条难度
- 报告结果时应同时报告均值和方差

3. 准确率阈值的选取

- 崩塌边界的定义依赖于阈值（如 70% 或 50%）
- 建议报告多个阈值下的 β ，展示 β 对阈值选择的鲁棒性
- 或者使用连续指标（如 AUC）而非二元阈值

4. 模型尺寸的对照

- 至少测两个模型尺寸（如 7B 和 13B）以验证 β 的物理含义
- 预测：更大模型 β 更小 $\rightarrow$ 深度惩罚更弱 $\rightarrow$ 崩塌边界在更大的 (L, B) 处
- 如果更大模型 β 不变或更大，需要重新审视理论

5. 位置编码的影响

- RoPE 等位置编码在长序列上的衰减可能贡献了部分 βL
- 可以对比不同位置编码方案（RoPE vs ALiBi vs NoPE）下的 β
- 这能让 β 从"黑箱常数"变为"可分解的架构效应"

6. 泛化 vs 记忆的混淆

- 在低深度训练 + 高深度测试场景中，模型的高准确率可能来自两种机制：
 - **真正的推理泛化：**学会了寻路策略，能推广到更长链
 - **局部模式匹配：**每步独立决策，不依赖长程一致性
- 如何区分？设计"陷阱测试"：在高深度测试中插入需要全局上下文才能正确决策的步（如"前面选了 A 所以这里必须选 B"），如果模型只在局部一致但全局矛盾，说明是模式匹配而非真推理